



OBCHODNĚ-TECHNICKÁ NABÍDKA

Rozvoj platformy Veslo

Enterprise Agent OS v1

Nabídka společnosti Coffee Workers s.r.o. pro Neatech s.r.o.

MAXIMÁLNÍ ROZPOČET	HODINOVÁ SAZBA	DOBA REALIZACE
7 980 000 Kč bez DPH	1 000 Kč bez DPH	nejpozději do 24 měsíců

Datum nabídky: 27. 7. 2026

Platnost nabídky: do 26. 8. 2026



1. Smluvní strany

DODAVATEL

Coffee Workers s.r.o.

Květinová 4465/34
466 01 Jablonec nad Nisou
IČO 07446861 | DIČ CZ07446861
KS Ústí nad Labem, oddíl C, vložka 42274
Ing. Josef Adam a Ing. Pavel Bucháček,
jednatelé

OBJEDNATEL

Neatech s.r.o.

Neklanova 150/38
Vyšehrad, 128 00 Praha 2
IČO 02481103 | DIČ CZ02481103
MS Praha, oddíl C, vložka 219919
Ing. Václav Soukup, jednatel

2. Manažerské shrnutí

Společnost Coffee Workers s.r.o. tímto předkládá společnosti Neatech s.r.o. nabídku na analýzu, návrh, vývoj, integraci a zavedení další generace platformy Veslo.

Cílem projektu je rozšířit Veslo do podoby Enterprise Agent OS v1 - jednotné platformy pro lokální a vzdálenou agentickou práci, sdílení projektů, práci s firemními znalostmi, automatizaci procesů a bezpečný provoz velkých generativních modelů v privátní výpočetní infrastruktuře.

Součástí řešení bude softwarová řídicí vrstva pro profesionální distribuovaný inference provoz velmi velkých modelů, včetně modelů třídy 10^{12} parametrů. Referenční architektura bude založena zejména na technologiích Kubernetes, Ray Serve LLM a vLLM, případně na srovnatelném inference enginu vybraném podle použitého modelu a výpočetní infrastruktury.

Obchodní rámec

Projekt bude realizován formou průběžně předávaných pracovních balíčků. Celkový rozpočtový limit činí 7 980 000 Kč bez DPH při hodinové sazbě 1 000 Kč bez DPH.

3. Cíle projektu

Výsledné řešení umožní Objednateli zejména:

- provozovat agentické úlohy lokálně i na vzdálené infrastruktuře;
- sdílet projekty mezi uživateli a řídit jejich oprávnění;
- synchronizovat vybraná projektová data a artefakty;
- využívat firemní znalostní zdroje s dohledatelnými citacemi;
- provozovat velké generativní a multimodální modely v privátní infrastruktuře;
- řídit distribuovaný inference provoz prostřednictvím Vesla;
- automatizovat opakované procesy včetně schvalovacích kroků;
- sledovat kvalitu, cenu, latenci a spolehlivost agentických operací;
- spravovat agenty, modely, nástroje, skills a konektory;
- připravit platformu pro enterprise a self-hosted nasazení.



4. Rozsah plnění

4.1 Platformová architektura

Dodavatel navrhne a implementuje potřebné změny platformové architektury, zejména:

- sjednocení identity projektů, workspace a konverzací;
- stabilizaci rozhraní mezi desktopovou aplikací, serverem a cloudovou částí;
- správu životního cyklu agentických běhů;
- recovery mechanismy při přerušení nebo selhání běhu;
- verzování a migrace konfigurace;
- rozhraní pro připojení dalších runtime a inference backendů;
- technickou, provozní a integrační dokumentaci.

4.2 Cloudové projekty a spolupráce

Součástí řešení bude:

- centrální identita projektu;
- členství uživatelů v projektu;
- role vlastník, správce, člen a čtenář;
- pozvánky a odebrání přístupu;
- sdílení vybraných konverzací, konfigurací a artefaktů;
- základní synchronizace mezi zařízeními;
- předání projektu nebo agentického běhu jinému uživateli;
- historie změn a audit přístupů.

Plnohodnotná realtime editace stejného obsahu více uživateli současně není součástí nabízené verze.

4.3 Remote Agent Runtime

Dodavatel rozšíří platformu o produkčně použitelnou podporu vzdálených agentů:

- vytvoření a připojení vzdáleného pracovního prostředí;
- spuštění, zastavení a obnovení vzdáleného agenta;
- bezpečné předání potřebné projektové konfigurace;
- správa přístupových tokenů a secrets;
- stav runtime, provozní logy a diagnostika;
- limity spotřeby a souběžných běhů;
- zotavení po výpadku spojení;
- základní správa životního cyklu vzdálených workspace.

Součástí nabídky je jeden referenční způsob vzdáleného nasazení. Multi-region infrastruktura není součástí základního rozsahu.

4.4 Enterprise Knowledge Fabric v1

Řešení bude obsahovat první produkční verzi firemní znalostní vrstvy:

- vytváření znalostních kolekcí;
- nahrávání souborů a připojení dohodnutých zdrojů;
- průběžnou aktualizaci podporovaných zdrojů;



-
- extrakci textu, struktury a metadat;
 - verzování dokumentů;
 - fulltextové a vektorové vyhledávání;
 - hybridní retrieval a reranking;
 - odpovědi s citacemi původních zdrojů;
 - přístupová oprávnění ke kolekcím;
 - odstranění dokumentu a souvisejících indexovaných dat;
 - administraci stavu zpracování;
 - základní evaluaci relevance a správnosti odpovědí.

Rozsah zahrnuje souborové zdroje a omezený počet již dostupných Google nebo Microsoft integrací. Nové specializované konektory budou podléhat samostatnému upřesnění.



4.5 Veslo Enterprise Inference Fabric

Dodavatel navrhne a implementuje softwarovou řídicí vrstvu pro profesionální provoz velmi velkých generativních, reasoning a multimodálních modelů.

Referenční architektura

- Kubernetes nebo kompatibilní clusterová platforma;
- Ray Serve LLM nebo srovnatelná orchestrace inference workloadů;
- vLLM jako primární inference engine;
- možnost připojit SGLang, TensorRT-LLM nebo jiný schválený backend;
- OpenAI-kompatibilní rozhraní pro platformu Veslo.

Funkční rozsah inference vrstvy

- registr modelů a jejich verzí;
- deklarativní konfigurace inference deploymentů;
- multi-node a multi-GPU serving;
- tensor, pipeline, data a expert parallelism;
- podpora velkých MoE architektur;
- řízení GPU placementu a požadavků na prostředky;
- fronty, priority a admission control;
- kvóty pro organizace, projekty a uživatele;
- continuous batching;
- správa KV cache a prefix-aware routing;
- oddělené inference pooly pro generování, embeddings a reranking;
- health checks a automatizované zotavení služby;
- rolling a canary deployment modelů;
- rollback na předchozí modelovou verzi;
- horizontální škálování, pokud jej umožní dostupná infrastruktura;
- sledování latence, time-to-first-token, throughputu a chybovosti;
- sledování využití GPU a orientačních provozních nákladů;
- autentizace, autorizace, síťová izolace a audit požadavků;
- výkonnostní a kompatibilitní benchmarky vybraných modelů.

Vymezení odpovědnosti

Softwarová vrstva bude připravena pro modely s řádově stovkami miliard až 10^{12} celkových parametrů. Skutečná provozuschopnost konkrétního modelu závisí na dostupném počtu GPU, velikosti GPU paměti, síťovém propojení clusteru, kvantizaci, architektuře modelu a jeho licenčních podmínkách.

Nabídka nezahrnuje vývoj vlastního inference enginu ani trénování základního modelu.

4.6 Automatizace a workflow

- časové a událostní spouštění automatizací;
- webhookové vstupy;
- opakované a plánované běhy;



- schvalovací kroky vyžadující zásah uživatele;
- retry mechanismy a evidenci neúspěšných běhů;
- historii provedených automatizací;
- notifikace o dokončení nebo chybě;
- základní sadu šablon agentických workflow.

Obecný vizuální no-code editor libovolných podnikových procesů není součástí této nabídky.

4.7 Governance a bezpečnost

- organizační a projektový RBAC;
- centrální auditní log;
- bezpečné ukládání přístupových údajů;
- správu povolených modelů, nástrojů a konektorů;
- základní retenční pravidla;
- export auditních událostí;
- řízení přístupu k inference endpointům;
- oddělení projektových a organizačních workloadů;
- integraci jednoho dohodnutého standardu jednotného přihlášení;
- přípravu rozhraní pro další enterprise identity systémy.

Kompletní SCIM provisioning, plnohodnotné DLP a formální bezpečnostní certifikace nejsou součástí základního rozsahu.

4.8 Observabilita a evaluace

- měření úspěšnosti agentických úloh;
- sledování latence a spotřeby modelových zdrojů;
- distribuované trasování jednotlivých kroků;
- administrátorský přehled běhů a chyb;
- sadu referenčních agentických úloh;
- modelové a inference benchmarky;
- evidenci použitého modelu, runtime a konfigurace;
- porovnání kvality a výkonu podporovaných modelů;
- základní provozní alerting.

4.9 Agent Teams a Skills Hub v1

- delegování úlohy dalšímu agentovi;
- základní supervisor workflow;
- omezení počtu agentů a spotřeby prostředků;
- sdílený projektový kontext;
- firemní katalog schválených skills;
- publikaci a instalaci interních skills;
- verzování a řízení nasazení skills;
- audit použitých agentů, nástrojů a skills.

Rozsáhlé autonomní týmy agentů s dynamickou změnou organizační struktury nejsou součástí verze v1.



4.10 Self-hosted a mobilní připravenost

- referenční self-hosted nasazení řídicí části Vesla;
- konfigurační a instalační dokumentaci;
- základní postup zálohování a obnovy;
- propojení self-hosted Vesla s privátním inference clusterem;
- responzivní rozhraní pro monitoring a schvalování;
- API připravené pro budoucí nativní mobilní aplikaci.

Plnohodnotný high-availability multi-region provoz ani samostatná nativní mobilní aplikace nejsou součástí této nabídky.



5. Výstupy projektu

Dodavatel předá Objednateli zejména:

- zdrojové kódy vytvořené v rámci projektu;
- databázové a konfigurační migrace;
- infrastrukturu jako kód v dohodnutém rozsahu;
- konfigurační šablony inference deploymentů;
- automatizované testy hlavních scénářů;
- technickou a provozní dokumentaci;
- bezpečnostní a provozní doporučení;
- dokumentaci API a integračních rozhraní;
- přehled podporovaných modelů a inference konfigurací;
- výsledky referenčních výkonnostních testů;
- podklady potřebné pro další provoz a rozvoj řešení.

Zdrojové kódy budou průběžně ukládány v repozitáři určeném Objednatelem.

6. Akceptační kritéria

Plnění bude akceptováno po ověření dohodnutých end-to-end scénářů, zejména:

- dva uživatelé mohou bezpečně sdílet jeden projekt;
- projekt lze provozovat na lokálním i vzdáleném runtime;
- agent může využít firemní knowledge base a vrátit dohledatelné citace;
- knowledge base respektuje nastavená přístupová oprávnění;
- automatizace může vyžádat schválení uživatele;
- administrátor může dohledat průběh a výsledek agentického běhu;
- Veslo komunikuje s privátním distribuovaným inference endpointem;
- referenční model lze nasadit prostřednictvím připravené inference vrstvy;
- modelový deployment lze monitorovat, aktualizovat a vrátit na předchozí verzi;
- supervisor agent může delegovat omezenou úlohu dalšímu agentovi;
- řešení lze nasadit v dohodnuté self-hosted konfiguraci;
- hlavní desktopové scénáře jsou pokryty automatizovanými end-to-end testy.

Akceptace velkého modelu

Nasazení konkrétního modelu třídy 10^{12} parametrů bude součástí akceptace pouze tehdy, pokud Objednatel poskytne odpovídající GPU infrastrukturu, síťové propojení a oprávnění k použití modelu. V opačném případě bude inference architektura ověřena na dostupné reprezentativní konfiguraci.

7. Organizace realizace

Projekt bude řízen iterativně. Dodavatel a Objednatel budou průběžně stanovovat priority pracovních balíčků tak, aby bylo možné pravidelně předávat funkční a ověřitelné části řešení.

Dodavatel může pro specializované části projektu využít odborné subdodavatele. Za jejich práci, zabezpečení přístupů a kvalitu výstupů odpovídá Dodavatel ve stejném rozsahu jako za vlastní plnění.



Přístup subdodavatelů k neveřejným systémům Objednatele podléhá předchozímu schválení Objednatelem.

Pravidelný projektový reporting bude obsahovat:

- přehled provedených prací;
- čerpání hodin a rozpočtu;
- stav pracovních balíčků;
- identifikovaná rizika a závislosti;
- plán činností pro následující období.

8. Doba realizace

Předpokládaná doba realizace je nejpozději 24 měsíců od zahájení projektu.

Zahájením projektu se rozumí uzavření smlouvy nebo potvrzení objednávky, zpřístupnění potřebných vývojových prostředí a jmenování odpovědných osob na obou stranách.

Pořadí jednotlivých pracovních balíčků může být po vzájemné dohodě změněno, pokud tím nebude rozšířen celkový rozsah nebo překročen maximální rozpočet.



9. Cena a hodinová sazba

Cenový model

Projekt bude realizován v režimu Time & Material s maximálním rozpočtovým limitem. Hodinová sazba činí 1 000 Kč bez DPH, maximální rozsah 7 980 hodin a maximální cena 7 980 000 Kč bez DPH.

Pracovní balíček	Rozsah	Cena bez DPH
Platformová architektura a stabilizace	550 h	550 000 Kč
Cloudové projekty, synchronizace a sdílení	900 h	900 000 Kč
Remote Agent Runtime	750 h	750 000 Kč
Enterprise Knowledge Fabric v1	950 h	950 000 Kč
Enterprise Inference Fabric	1 750 h	1 750 000 Kč
Automatizace, observabilita a evaluace	650 h	650 000 Kč
Governance, bezpečnost a konektory	550 h	550 000 Kč
Agent Teams, Skills Hub, self-hosted a mobilní připravenost	550 h	550 000 Kč
Integrace, UX, testování, dokumentace a vedení projektu	1 330 h	1 330 000 Kč
CELKEM	7 980 h	7 980 000 Kč

Rozdělení hodin mezi pracovní balíčky je orientační. Hodiny lze po schválení Objednatelem převádět mezi balíčky, aniž by došlo ke zvýšení maximální ceny.

Dodavatel není oprávněn překročit maximální rozpočet bez předchozího písemného souhlasu Objednatele.

10. Fakturace a platební podmínky

Fakturace bude probíhat měsíčně podle skutečně odpracovaných a vykázaných hodin.

Dodavatel předloží spolu s fakturou:

- výkaz provedených činností;
- počet hodin podle pracovních balíčků;
- aktuální čerpání rozpočtu;
- stručný přehled dosažených výstupů.

Splatnost faktur je 14 kalendářních dnů.

Případné práce nad maximální rozsah budou provedeny pouze na základě písemně schváleného změnového požadavku. Pro takové práce bude zachována hodinová sazba 1 000 Kč bez DPH, nebude-li písemně dohodnuto jinak.



11. Součinnost Objednatele

Objednatel zajistí zejména:

- přístup ke zdrojovým kódům a vývojovým prostředím;
- přístup k potřebné projektové dokumentaci;
- testovací účty a integrační prostředí;
- rozhodování o produktových prioritách;
- dostupnost odpovědných osob pro konzultace a akceptaci;
- GPU infrastrukturu nebo přístup k ní pro ověření distribuovaného inference;
- licence a oprávnění k použití vybraných modelů;
- potřebné účty a licence služeb třetích stran.

Prodlení způsobené neposkytnutím potřebné součinnosti může přiměřeně posunout předpokládanou dobu dokončení.



12. Duševní vlastnictví

Majetková práva k programovým částem vytvořeným specificky pro Objednatele přejdou na Objednatele po úplném zaplacení příslušného plnění.

Komponenty třetích stran a open-source software zůstávají pod svými původními licenčními podmínkami. Dodavatel provede přehled významných použitých závislostí a jejich licencí.

Dodavatel není oprávněn využít neveřejné zdrojové kódy, data ani obchodní informace Objednatele pro jiné zákazníky nebo pro trénování modelů.

13. Bezpečnost a důvěrnost

Dodavatel se zaváže chránit veškeré neveřejné informace Objednatele a používat je výhradně za účelem plnění projektu.

Bez předchozího souhlasu Objednatele nebudou projektová data:

- předávána třetím stranám;
- používána k trénování modelů;
- ukládána mimo schválená prostředí;
- odesílána do veřejných AI služeb.

Přístupy do systémů budou poskytovány pouze v nezbytném rozsahu a budou po ukončení příslušné činnosti odebrány.

14. Záruka

Dodavatel poskytne tříměsíční záruku na vady předaného řešení, které představují prokazatelný nesoulad s odsouhlasenými akceptačními kritérii.

Odstranění takových vad nebude účtováno jako dodatečná práce. Záruka se nevztahuje na vady způsobené:

- změnou systémů nebo konfigurace třetí stranou;
- změnou API externí služby;
- nekompatibilní aktualizací modelu nebo inference engine;
- nedostupností či nedostatečným výkonem infrastruktury;
- použitím řešení v rozporu s dokumentací.

Navazující provozní podpora a SLA mohou být sjednány samostatnou servisní smlouvou.

15. Výluky z nabídky

Cena nezahrnuje:

- nákup, pronájem ani fyzickou instalaci GPU hardwaru;
- cloudové a hostingové poplatky;
- síťovou infrastrukturu a datacentrové služby;
- licence modelů a placených služeb třetích stran;
- trénování základních modelů;
- rozsáhlý fine-tuning modelů třídy 10^{12} parametrů;
- vývoj vlastního inference engine;



-
- formální bezpečnostní nebo regulatorní certifikace;
 - nepřetržitý dohled v režimu 24/7;
 - plnohodnotnou nativní mobilní aplikaci;
 - multi-region high-availability infrastrukturu;
 - integrace a migrace nad výslovně dohodnutý rozsah.

16. Závěrečná ustanovení

Tato nabídka představuje obchodní a technický návrh Dodavatele. Samotné zahájení realizace bude podmíněno uzavřením smlouvy o dílo, rámcové smlouvy nebo písemným potvrzením objednávky obsahující alespoň rozsah, cenu, způsob akceptace a pravidla ochrany důvěrných informací.

V Jablonci nad Nisou dne 27. 7. 2026